

Segmentación de entidades federativas de México según patrones de accidentes de tránsito: el caso de Morelos

Resumen

Este artículo analiza datos públicos oficiales de accidentes de tránsito en México, publicados por la SICT en datos.gob.mx. A partir de dos conjuntos de datos —accidentes por día/condición de luz, y por mes con heridos y muertos— se construyeron variables de tasa y proporción por entidad federativa (letalidad, tasa de heridos, proporción en fin de semana y en horario nocturno/crepuscular). Con ellas se aplicó KMeans para agrupar a las 32 entidades y ubicar en qué grupo cae Morelos y qué lo caracteriza. El análisis sugiere que Morelos no destaca por la severidad de sus accidentes —su letalidad está entre las más bajas del país— sino por una concentración temporal inusual: la proporción más alta de accidentes nocturnos/crepusculares del país y la segunda más alta en fin de semana. Se discuten las limitaciones: agregación estatal, muestra pequeña e imposibilidad de derivar causalidad.

Introducción

Los accidentes de tránsito suelen analizarse por conteo bruto de casos, más que como un problema de *patrones*. Preguntas como "¿en qué se parece Morelos a otros estados en accidentalidad?" requieren comparar patrones, no solo volúmenes.

Este proyecto integra el ciclo completo de un análisis de datos aplicado —búsqueda de fuente pública, limpieza, análisis exploratorio, modelado no supervisado, interpretación y limitaciones— en el marco del **Tema 4: movilidad, transporte o accidentes con datos públicos**, con foco en Morelos, sede de la institución de los autores.

La pregunta guía es: *¿qué patrones aparecen en los datos de accidentes de tránsito en México, y en qué grupo se ubica Morelos frente a las demás entidades?* No es un estudio causal, sino un análisis descriptivo por semejanza estadística en un conjunto acotado de variables.

Fuente de datos

Los datos provienen del dataset "**Accidentes de tránsito**", publicado por la SICT en el Portal de Datos Abiertos de México (datos.gob.mx/dataset/accidentes_transito), bajo licencia CC-BY-4.0. Se usaron dos recursos: **por día de la semana** (`sct_70_accidentes_dia.csv`, totales y mortales por día y por condición de luz) y **por mes** (`sct_71_accidentes_mes.csv`, accidentes, heridos, muertos y daños materiales por entidad y mes).

Ambos están agregados a nivel de **entidad federativa**, no municipal. Se buscó una fuente con desagregación municipal para Morelos (incluido el programa ATUS de INEGI), pero no se logró un CSV de descarga directa con ese nivel en el tiempo disponible (búsqueda documentada en `referencias/fuentes_datos.txt`), por lo que el análisis se hace a nivel nacional, usando a Morelos como caso de estudio. Los metadatos del recurso (vía la API de CKAN) tampoco especifican el año exacto de los registros, solo las fechas de creación/actualización (julio-agosto de 2025); esto se documenta como limitación.

Preparación de datos

No se encontraron nulos ni filas duplicadas, y ambos archivos cubrían las 32 entidades. Se hicieron dos ajustes: en el archivo por día, la columna accidentes no es un conteo sino una **etiqueta de tipo de registro** (cada entidad aparece dos veces: "accidentes" y "accidentes mortales"), por lo que fue necesario separarlos antes de construir variables; y los nombres de entidades en formato no estándar (p. ej. "Ciudad De Mexico") se homologaron a la forma estándar para combinar ambos archivos sin errores.

Ambos datasets se combinaron por entidad: del mensual se calcularon totales anuales de accidentes, heridos, muertos y daños; del diario, la fracción de accidentes en fin de semana y en condición de luz crepuscular/nocturna.

Se optó por **tasas y proporciones**, no solo totales: comparar directamente los accidentes de la Ciudad de México con los de Colima favorecería a los estados grandes por tamaño de población y parque vehicular. Normalizar por el total de accidentes hace la comparación más justa y orientada a *patrones*. El dataset limpio, con 32 filas, se guardó en `data/processed/dataset_limpio.csv`.

Análisis exploratorio

La tasa de letalidad nacional promedia **~24.6 muertos por cada 100 accidentes** (máximos en Coahuila, 40.4, y Jalisco, 38.0). La proporción de fin de semana promedia **36.6%**, y la nocturna/crepuscular **46.1%**.

Morelos: en volumen total ocupa el lugar 24 de 32 (201 accidentes, 118 heridos, 23 fallecidos); en letalidad registra **~11.4**, de los tres valores más bajos del país (lugar 30 de 32); en fin de semana, **47.8%**, la segunda más alta tras la Ciudad de México (49.3%); y en horario nocturno/crepuscular, **54.7%**, la más alta de las 32 entidades.

Esta combinación —letalidad baja pero concentración temporal muy por encima del promedio nacional— motiva un modelo que combine varias variables a la vez. Se ilustra en la **Gráfica 1** (accidentes totales por entidad, Morelos resaltado) y en la **Gráfica 2** (fin de semana vs. nocturna, por cluster), donde Morelos aparece desplazado hacia la esquina superior derecha.

Metodología

Se aplicó **KMeans** porque el objetivo no es predecir una etiqueta ya conocida, sino **descubrir agrupaciones** con patrones similares. Se usaron cuatro variables (tasa de letalidad, tasa de heridos, proporción de fin de semana y proporción nocturna/crepuscular), sin incluir variables de volumen, para que el agrupamiento reflejara *comportamiento* y no separara simplemente estados grandes de pequeños. Las variables se estandarizaron con `StandardScaler`, ya que tienen escalas distintas (la letalidad puede superar 40, las proporciones están entre 0 y 1) y sin este paso la de mayor escala dominaría el cálculo de distancias.

Para elegir k se calculó el coeficiente de silueta entre 2 y 6 (valores entre 0.246 y 0.299, sin separación fuertemente marcada, algo esperable con solo 32 observaciones). Se optó por **$k=3$** , con coeficiente competitivo y un número de grupos manejable e interpretable.

Resultados

El modelo con $k=3$ agrupó a las 32 entidades en clusters de 15, 11 y 6. Morelos quedó en el **cluster 0** (15 entidades), junto con Jalisco, Guerrero, Puebla, Guanajuato y Estado de México, entre otros (lista

completa en `outputs/resultados_modelo.csv`).

Cluster	n	Letalidad (prom.)	Heridos (prom.)	% fin de semana	% nocturno
0 (incluye Morelos)	15	27.8	73.0	38.6%	48.1%
1	11	16.5	65.6	33.1%	46.5%
2	6	31.1	111.0	38.3%	40.3%

Un dato clave: **Morelos es un valor atípico dentro de su propio cluster** en letalidad. El promedio del cluster 0 es 27.8; Morelos registra 11.4, muy por debajo del promedio del grupo y del nacional. En las variables de patrón temporal, en cambio, se ubica en el extremo superior de las 32 entidades.

Interpretación

Con los datos disponibles se observa que Morelos queda agrupado con estados de letalidad relativamente alta **no porque comparta ese nivel de letalidad**, sino porque comparte con ellos un patrón temporal marcado: en conjunto, sus cuatro variables resultaron más cercanas a ese grupo que a los otros dos, aun cuando en letalidad se parece más al cluster 1.

Esto sugiere una posible asociación entre los accidentes en Morelos y patrones de movilidad nocturna y de fin de semana. Sin embargo, **este análisis no permite afirmar causalidad**: no se cuenta con datos sobre causas, tipo de vía, tipo de vehículo o consumo de alcohol, necesarios para eso. Sí se puede decir con confianza que el patrón temporal de Morelos es estadísticamente distinto —y más marcado— que el de la mayoría de las demás entidades, lo cual ilustra un punto metodológico: un modelo de agrupamiento puede colocar una observación en un grupo por razones distintas a las esperadas.

Limitaciones

- **Nivel de agregación:** datos por entidad (32 registros), no municipal; no fue posible replicar el análisis por municipio de Morelos con fuentes descargables en el plazo disponible.
- **Periodo no explicitado:** los metadatos solo indican fechas de publicación/actualización (2025), no el año exacto de referencia.
- **Tamaño de muestra:** 32 observaciones limitan la robustez del agrupamiento; el mejor coeficiente de silueta (0.299) es moderado.
- **Variables faltantes:** no se contó con tipo de vehículo, tipo de vialidad ni causa reportada.
- **Ausencia de causalidad:** el modelo agrupa por semejanza estadística, no demuestra que el horario nocturno o el fin de semana *causen* más accidentes.
- **Dependencia de las variables elegidas:** otro conjunto de variables probablemente produciría una segmentación distinta.

Conclusiones

Este proyecto aplicó un flujo completo de análisis de datos públicos —búsqueda de fuente oficial, limpieza, construcción de variables, análisis exploratorio, modelado no supervisado e interpretación— centrado en el patrón de accidentalidad de Morelos frente a las demás entidades.

Con los datos disponibles, Morelos no se distingue por la severidad de sus accidentes —su letalidad está entre las más bajas del país— sino por una concentración temporal particular: la proporción más alta de accidentes nocturnos/crepusculares del país y la segunda más alta en fin de semana. Esto no debe leerse como explicación definitiva, sino como punto de partida para preguntas de seguimiento: con datos más desagregados (municipales, por vialidad o causa) sería posible explorar si el patrón se relaciona con zonas, vehículos o comportamientos de movilidad específicos.

Referencias

1. SICT. *Accidentes de tránsito* [conjunto de datos]. datos.gob.mx: https://www.datos.gob.mx/dataset/accidentes_transito (consultado el 22 de agosto de 2026). Licencia CC-BY-4.0.
2. INEGI. *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS)*: <https://www.inegi.org.mx/programas/accidentes/> (fuente exploratoria, ver [referencias/fuentes_datos.txt](#)).
3. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR, 12, 2825-2830.
4. McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proc. 9th Python in Science Conf.