

Segmentación de entidades federativas de México según patrones de accidentes de tránsito: el caso de Morelos

Autores: Ruiz Santos Orlando, Ventura Gil Astrid Valeria, Ocampo Martínez Angel Daniel, Medina Villa Abril Aidee **Materia:** Extracción de Conocimiento de Bases de Datos — 9° A **Palabras clave:** accidentes de tránsito, movilidad, datos abiertos, aprendizaje no supervisado, KMeans, Morelos

Resumen

Este artículo analiza datos públicos oficiales de accidentes de tránsito en México, publicados por la SICT en `datos.gob.mx`. A partir de dos conjuntos de datos —accidentes por día/condición de luz, y por mes con heridos y muertos— se construyeron variables de tasa y proporción por entidad federativa (letalidad, tasa de heridos, proporción en fin de semana y en horario nocturno/crepuscular). Con ellas se aplicó KMeans para agrupar a las 32 entidades y ubicar en qué grupo cae Morelos y qué lo caracteriza. El análisis sugiere que Morelos no destaca por la severidad de sus accidentes —su letalidad está entre las más bajas del país— sino por una concentración temporal inusual: la proporción más alta de accidentes nocturnos/crepusculares del país y la segunda más alta en fin de semana. Se discuten las limitaciones: agregación estatal, muestra pequeña e imposibilidad de derivar causalidad.

Introducción

Los accidentes de tránsito suelen analizarse por conteo bruto de casos, más que como un problema de *patrones*. Preguntas como “¿en qué se parece Morelos a otros estados en accidentalidad?” requieren comparar patrones, no solo volúmenes. Un estado puede registrar pocos accidentes en términos absolutos y, aun así, presentar un comportamiento estadísticamente distinto al del resto del país si se observan sus proporciones internas en lugar de sus totales.

Este proyecto integra el ciclo completo de un análisis de datos aplicado —búsqueda de fuente pública, limpieza, análisis exploratorio, modelado no supervisado, interpretación y limitaciones— en el marco del **Tema 4: movilidad, transporte o accidentes con datos públicos**, con foco en Morelos, sede de la institución de los autores.

La pregunta guía es: *¿qué patrones aparecen en los datos de accidentes de tránsito en México, y en qué grupo se ubica Morelos frente a las demás entidades?* No es un estudio causal, sino un análisis descriptivo por semejanza estadística en un conjunto acotado de variables. La relevancia de esta pregunta no está en señalar qué estado tiene “más” o “menos” accidentes, sino en identificar si existen agrupaciones de comportamiento que ayuden a entender mejor el caso local antes de compararlo, de forma superficial, contra el promedio nacional.

Fuente de datos

Los datos provienen del dataset “**Accidentes de tránsito**”, publicado por la SICT en el Portal de Datos Abiertos de México (`datos.gob.mx/dataset/accidentes_transito`), bajo licencia CC-BY-4.0. Se usaron dos recursos: **por día de la semana** (`sct_70_accidentes_dia.csv`, totales y mortales por día y por condición de luz) y **por mes** (`sct_71_accidentes_mes.csv`, accidentes, heridos, muertos y daños materiales por entidad y mes).

Del recurso mensual se utilizaron los conteos de accidentes, heridos y muertos para construir las tasas de severidad; la variable de daños materiales estimados (en millones de pesos) se revisó durante la exploración pero se excluyó de las variables finales del modelo, ya que introduce una dimensión económica —dependiente de valores de mercado y no solo de la dinámica de los accidentes— que no aporta directamente a responder la pregunta guía sobre patrones de severidad y horario.

Ambos están agregados a nivel de **entidad federativa**, no municipal. Se buscó una fuente con desagregación municipal para Morelos (incluido el programa ATUS de INEGI), pero no se logró un CSV de descarga directa con ese nivel en el tiempo disponible (búsqueda documentada en `referencias/fuentes_datos.txt`), por lo

que el análisis se hace a nivel nacional, usando a Morelos como caso de estudio. Se consultaron los metadatos del recurso a través de la API pública de CKAN de datos.gob.mx (`/api/3/action/package_show`); estos únicamente exponen las fechas de creación y actualización del recurso en el portal (julio–agosto de 2025), sin especificar el año exacto al que corresponden los registros, lo cual se documenta como limitación.

Preparación de datos

No se encontraron nulos ni filas duplicadas, y ambos archivos cubrían las 32 entidades. Se hicieron dos ajustes: en el archivo por día, la columna **accidentes** no es un conteo sino una **etiqueta de tipo de registro** (cada entidad aparece dos veces: "**accidentes**" y "**accidentes mortales**"), por lo que fue necesario separarlos antes de construir variables; y los nombres de entidades en formato no estándar (p. ej. "**Ciudad De Mexico**") se homologaron a la forma estándar para combinar ambos archivos sin errores.

Ambos datasets se combinaron por entidad: del mensual se calcularon totales anuales de accidentes, heridos, muertos y daños; del diario, la fracción de accidentes en fin de semana y en condición de luz crepuscular/nocturna. La combinación se hizo con una unión interna (**inner join**) por nombre de entidad, lo que garantiza que solo se conserven registros presentes en ambas fuentes; dado que las 32 entidades aparecían en los dos archivos tras la homologación de nombres, no se perdió ninguna fila en este paso.

Se optó por **tasas y proporciones**, no solo totales: comparar directamente los accidentes de la Ciudad de México con los de Colima favorecería a los estados grandes por tamaño de población y parque vehicular. Normalizar por el total de accidentes hace la comparación más justa y orientada a *patrones*. Por la misma razón, la variable de daños materiales —que depende de escala económica y no solo de comportamiento vial— se dejó fuera de las variables finales, priorizando severidad humana (letalidad, heridos) y patrón temporal (fin de semana, horario) como los ejes de comparación. El dataset limpio, con 32 filas, se guardó en `data/processed/dataset_limpio.csv`.

Análisis exploratorio

La tasa de letalidad nacional promedia **~24.6 muertos por cada 100 accidentes**. Los valores más altos corresponden a Coahuila (40.4) y Jalisco (38.0); en el extremo opuesto, las tasas más bajas del país son las de Tlaxcala (6.7), Tabasco (10.3) y Morelos (11.4) —los tres únicos estados por debajo de 12—, lo cual ya adelanta que Morelos no es un caso típico en severidad. La proporción de fin de semana promedia **36.6%**, y la nocturna/crepuscular **46.1%**.

En volumen total de accidentes, la distribución entre entidades es marcadamente desigual: Veracruz concentra el mayor número (1,290 accidentes anuales), mientras que la Ciudad de México registra el menor (67), a pesar de ser la entidad con mayor densidad poblacional del país. Esto confirma que el volumen bruto refleja más bien diferencias de reporte, tamaño de red vial y exposición vehicular que un comportamiento comparable entre entidades, y refuerza la decisión metodológica de trabajar con tasas y proporciones en el resto del análisis.

Morelos: en volumen total ocupa el lugar 24 de 32 (201 accidentes, 118 heridos, 23 fallecidos); en letalidad registra **~11.4**, de los tres valores más bajos del país (lugar 30 de 32); en fin de semana, **47.8%**, la segunda más alta tras la Ciudad de México (49.3%); y en horario nocturno/crepuscular, **54.7%**, la más alta de las 32 entidades, seguida de cerca por Tlaxcala (53.4%). Es notable que estas dos entidades —Morelos y Tlaxcala— comparten tanto una letalidad baja como una alta concentración nocturna, lo que sugiere que este patrón temporal no es exclusivo de Morelos, sino potencialmente compartido por entidades del centro del país con características similares de movilidad.

Esta combinación —letalidad baja pero concentración temporal muy por encima del promedio nacional— motiva un modelo que combine varias variables a la vez, en lugar de analizar cada una por separado. Se ilustra en la **Gráfica 1** (accidentes totales por entidad, Morelos resaltado) y en la **Gráfica 2** (fin de semana vs. nocturna, por cluster), donde Morelos aparece desplazado hacia la esquina superior derecha.

Metodología

Se aplicó **KMeans** porque el objetivo no es predecir una etiqueta ya conocida, sino **descubrir agrupaciones** con patrones similares; no existe una variable objetivo previa (como “tipo de entidad”) que justifique un enfoque supervisado. Se descartaron alternativas como el agrupamiento jerárquico por simplicidad de interpretación con pocas observaciones, y KMeans se prefirió por ser el algoritmo de agrupamiento cubierto en el curso y por producir un número fijo y fácil de comunicar de grupos, algo conveniente dado que el objetivo final es explicar la posición de una sola entidad (Morelos) frente al resto.

Se usaron cuatro variables (tasa de letalidad, tasa de heridos, proporción de fin de semana y proporción nocturna/crepuscular), sin incluir variables de volumen, para que el agrupamiento reflejara *comportamiento* y no separara simplemente estados grandes de pequeños. Las variables se estandarizaron con **StandardScaler**, ya que tienen escalas distintas (la letalidad puede superar 40, las proporciones están entre 0 y 1) y sin este paso la de mayor escala dominaría el cálculo de distancias.

Para elegir k se calculó el coeficiente de silueta entre 2 y 6 (valores entre 0.246 y 0.299, sin separación fuertemente marcada, algo esperable con solo 32 observaciones). Se optó por **k=3**, con coeficiente competitivo y un número de grupos manejable e interpretable. El modelo se ajustó con semilla fija (**random_state=42**) y diez inicializaciones (**n_init=10**) para reducir la sensibilidad de KMeans a la inicialización aleatoria de los centroides y hacer el resultado reproducible entre ejecuciones.

Resultados

El modelo con $k=3$ agrupó a las 32 entidades en clusters de 15, 11 y 6. Morelos quedó en el **cluster 0** (15 entidades), junto con Jalisco, Guerrero, Puebla, Guanajuato y Estado de México, entre otros (lista completa en `outputs/resultados_modelo.csv`).

Cluster	n	Letalidad (prom.)	Heridos (prom.)	% fin de semana	% nocturno
0 (incluye Morelos)	15	27.8	73.0	38.6%	48.1%
1	11	16.5	65.6	33.1%	46.5%
2	6	31.1	111.0	38.3%	40.3%

Los tres clusters tienen perfiles distinguibles: el **cluster 1** (11 entidades, entre ellas Chiapas, Querétaro, Tabasco y Veracruz) agrupa a los estados con la letalidad promedio más baja de los tres grupos; el **cluster 2** (el más pequeño, 6 entidades, incluida la Ciudad de México, Coahuila, Durango, Sonora, Tamaulipas y Zacatecas) tiene la tasa de heridos más alta y, en contraste, la proporción nocturna más baja de los tres, lo que sugiere un patrón de accidentalidad más diurna y con más lesionados por evento; y el **cluster 0**, donde cae Morelos, es el que combina letalidad relativamente alta con la mayor concentración de fin de semana y horario nocturno de los tres grupos.

Un dato clave: **Morelos es un valor atípico dentro de su propio cluster** en letalidad. El promedio del cluster 0 es 27.8; Morelos registra 11.4, muy por debajo del promedio del grupo y del nacional. En las variables de patrón temporal, en cambio, se ubica en el extremo superior de las 32 entidades.

Interpretación

Con los datos disponibles se observa que Morelos queda agrupado con estados de letalidad relativamente alta **no porque comparta ese nivel de letalidad**, sino porque comparte con ellos un patrón temporal marcado: en conjunto, sus cuatro variables resultaron más cercanas a ese grupo que a los otros dos, aun cuando en letalidad se parece más al cluster 1.

Esto sugiere una posible asociación entre los accidentes en Morelos y patrones de movilidad nocturna y de fin de semana. Sin embargo, **este análisis no permite afirmar causalidad**: no se cuenta con datos

sobre causas, tipo de vía, tipo de vehículo o consumo de alcohol, necesarios para eso. Sí se puede decir con confianza que el patrón temporal de Morelos es estadísticamente distinto —y más marcado— que el de la mayoría de las demás entidades, lo cual ilustra un punto metodológico: un modelo de agrupamiento puede colocar una observación en un grupo por razones distintas a las esperadas.

Limitaciones

- **Nivel de agregación:** datos por entidad (32 registros), no municipal; no fue posible replicar el análisis por municipio de Morelos con fuentes descargables en el plazo disponible.
- **Periodo no explicitado:** los metadatos solo indican fechas de publicación/actualización (2025), no el año exacto de referencia.
- **Tamaño de muestra:** 32 observaciones limitan la robustez del agrupamiento; el mejor coeficiente de silueta (0.299) es moderado.
- **Variables faltantes:** no se contó con tipo de vehículo, tipo de vialidad ni causa reportada.
- **Ausencia de causalidad:** el modelo agrupa por semejanza estadística, no demuestra que el horario nocturno o el fin de semana *causen* más accidentes.
- **Dependencia de las variables elegidas:** otro conjunto de variables probablemente produciría una segmentación distinta.

Conclusiones

Este proyecto aplicó un flujo completo de análisis de datos públicos —búsqueda de fuente oficial, limpieza, construcción de variables, análisis exploratorio, modelado no supervisado e interpretación— centrado en el patrón de accidentalidad de Morelos frente a las demás entidades.

Con los datos disponibles, Morelos no se distingue por la severidad de sus accidentes —su letalidad está entre las más bajas del país— sino por una concentración temporal particular: la proporción más alta de accidentes nocturnos/crepusculares del país y la segunda más alta en fin de semana. Esto no debe leerse como explicación definitiva, sino como punto de partida para preguntas de seguimiento: con datos más desagregados (municipales, por vialidad o causa) sería posible explorar si el patrón se relaciona con zonas, vehículos o comportamientos de movilidad específicos.

De cara a una continuación de este trabajo, dos líneas parecen las más valiosas: primero, gestionar acceso a microdatos con mayor desagregación geográfica y temporal —por ejemplo a través del Repositorio Nacional de Metadatos de INEGI o solicitando directamente a servicios escolares o dependencias estatales datos a nivel municipal para Morelos—; y segundo, incorporar variables de causa y tipo de vialidad que permitan pasar de una asociación estadística descriptiva a hipótesis más específicas sobre por qué el patrón nocturno y de fin de semana es tan pronunciado en esta entidad.

Referencias

1. SICT. *Accidentes de tránsito* [conjunto de datos]. datos.gob.mx: https://www.datos.gob.mx/dataset/accidentes_transito (consultado el 22 de agosto de 2026). Licencia CC-BY-4.0.
2. INEGI. *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS)*: <https://www.inegi.org.mx/programas/atus> (fuente exploratoria, ver `referencias/fuentes_datos.txt`).
3. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR, 12, 2825-2830.
4. McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proc. 9th Python in Science Conf.